

Conversa - Estruturação de Vaga

Entrevista estruturada para Engenheiro(a) de Machine Learning (Applied/Prod).

Usuário

: Engenheiro(a) de Machine Learning (Applied/Prod)

Assistente

Perfeito — e qual é o propósito principal desse cargo (o que essa pessoa vai entregar de valor no dia a dia)?

Usuário

Você curte resolver problemas e prefere código, já tem base forte em automação (Python) e dados (T-SQL), e seu interesse direto é IA. Esse combo é perfeito para trabalhar com modelos na prática: preparar dados, treinar, avaliar e colocar em produção de forma útil.

Assistente

Entendi.

2. SENIORIDADE: qual é a senioridade esperada para essa vaga e por quê?

Usuário

senior

Assistente

3. STACK: quais tecnologias, frameworks e práticas são essenciais para essa vaga?

Usuário

CORE SKILLS (essenciais):

Python para ML em produção (pandas/pyarrow, scikit-learn, FastAPI, testes, typing, logging)

SQL + modelagem de dados (joins, janelas, CTEs, qualidade, métricas)

MLOps básico aplicado (pipelines, MLflow/experiment tracking, deploy, monitoramento, CI/CD)

NICE-TO-HAVE (complementares):

Cloud (AWS) e serviços de ML (S3, IAM, SageMaker/alternativas)

Sistemas e performance (Docker avançado, cache, filas, observabilidade)

FERRAMENTAS E TECNOLOGIAS:

Python (pandas, scikit-learn, PyTorch "quando fizer sentido"), Jupyter

MLflow (ou W&B), FastAPI, Docker, Git, CI/CD

Orquestração (Airflow/Prefect) + banco (PostgreSQL/SQL Server) + monitoramento (Prometheus/Grafana ou equivalente)

Assistente

4. SOFT SKILLS: quais comportamentos ou atitudes são mais valorizados nessa vaga?

Usuário

VISÃO DO DIA A DIA

Como é o trabalho de um(a) Engenheiro(a) de Machine Learning (Applied/Prod):

transformar um problema de negócio em métrica + experimento (o que é "bom", como medir, como evitar viés)

preparar dados e features (SQL + pipelines, validação, versionamento e qualidade)

treinar modelos, comparar baselines e fazer avaliação sólida (offline/online, drift, fairness quando aplicável)

colocar em produção: API/serving + batch scoring, CI/CD, testes e infraestrutura

monitorar e iterar: alertas, drift, performance, custo, e re-treino controlado

Assistente

Boa — isso descreve bem o "mindset" e rotina. Mas pra fechar o tema soft skills, eu preciso que você traduza isso em comportamentos/atitudes observáveis.

Quais são as 3 a 6 atitudes mais valorizadas? (ex.: ownership ponta a ponta, comunicação com negócio, pragmatismo com baselines, rigor com métricas/qualidade, colaboração com engenharia, etc.)

Usuário

comunicacao e transparencia

Assistente

Anotado: comunicação e transparência como valores centrais.

Antes de eu gerar o resumo analítico, confirme por favor: posso fechar a entrevista e produzir o resumo agora?

Usuário

sim

Assistente

Resumo analítico da vaga (entrevista estruturada)

1) Título e propósito

Vaga: Engenheiro(a) de Machine Learning (Applied/Prod)

Propósito do cargo: transformar capacidade de dados + automação em modelos úteis em produção.

O foco é "ML que roda e gera impacto": definir métricas e experimentos, construir features/pipelines, treinar e avaliar modelos, e operar tudo em produção com monitoramento e iteração contínua.

Sinal forte do escopo: não é "pesquisa de modelo" isolada; é engenharia aplicada: do problema de negócio à entrega operacional (serving/batch + monitoramento + retraining).

2) Senioridade

Senioridade esperada: Sênior

Racional implícito: o cargo exige autonomia ponta a ponta e capacidade de decisão em trade-offs (métrica vs. viabilidade, baseline vs. complexidade, custo vs. performance, risco vs. velocidade), além de maturidade para desenhar/operar pipelines e produção com qualidade.

Onde o "sênior" aparece na prática:

- definir "o que é bom" (métrica) e como provar (experimento)
- colocar modelo em produção com testes, CI/CD, observabilidade
- monitorar, detectar drift e controlar retrain sem quebrar o produto

3) Stack essencial e práticas

Core (essenciais):

- Python para ML em produção: pandas/pyarrow, scikit-learn, FastAPI, testes, typing, logging
- SQL + modelagem de dados: joins, janelas, CTEs, qualidade e métricas
- MLOps aplicado (básico, mas real): pipelines, tracking (MLflow/W&B), deploy, monitoramento, CI/CD

Nice-to-have (acelera e amplia alcance):

- Cloud AWS: S3, IAM, SageMaker (ou equivalentes)
- Sistemas/performance: Docker avançado, cache, filas, observabilidade

Ferramentas citadas:

Python (pandas, scikit-learn; PyTorch quando fizer sentido), Jupyter, MLflow (ou W&B), FastAPI, Docker, Git, CI/CD, Airflow/Prefect, PostgreSQL/SQL Server, Prometheus/Grafana (ou equivalente).

Leitura do desenho técnico: stack bem alinhada para serving via API + batch scoring, com pipeline/orquestração e telemetria. (Ou seja: engenharia de produto com ML, não notebook-only.)

4) Soft skills valorizadas

Você destacou explicitamente:

- Comunicação
- Transparência

Tradução para comportamentos observáveis (como isso se manifesta):

- explicitar trade-offs (ex.: "ganho de AUC vs. custo/latência")
- alinhar expectativas com stakeholders sobre métricas, limites e riscos
- reportar problemas cedo (drift, dados ruins, dívida técnica) com plano claro
- documentar decisões: por que um baseline venceu/foi escolhido, por que um experimento foi encerrado, etc.

O "perfil ideal" que emerge do conjunto

Um(a) Engenheiro(a) de ML Applied/Prod que:

- pensa em métrica/impacto antes de escolher modelo
- é forte em dados (SQL + qualidade) e engenharia (API, testes, CI/CD, Docker)
- domina o mínimo necessário de MLOps para operar com segurança
- comunica com clareza e mantém transparência operacional (status real, riscos, limitações)

Se você quiser, no próximo passo eu posso transformar esse resumo em um roteiro de entrevista técnica (perguntas e sinais de avaliação) sem virar job description.

Usuário

gere um pdf dessa conversa